

Emisión de CO_2 de vehículos que circulan en México en base a sus características

Luis Felipe Rangel Salazar

Julio 2024

1. Introducción

El conjunto de datos con el que se va a trabajar representa un listado de distintos vehículos que circulan en México junto con sus características.

El objetivo del trabajo es identificar las principales características de un vehículo que afectan en su cantidad de emisiones de CO_2 .

Se pretende hacer un análisis predictivo del nivel de contaminante que emiten los vehículos en base a algunas de sus características, y por consecuencia en la cantidad de dióxido de carbono (CO_2) que emiten, aplicando algunos métodos de Aprendizaje Supervisado o No Supervisado.

2. Descripción de los datos

La base de datos consta de 4,601 registros con 19 variables originalmente.

- CO_2 (g/km) [variable objetivo]
- Marca
- Submarca
- Versión
- Modelo
- Trans.
- Comb.
- Cilindros
- Categoría
- R. Ciudad (km/l)
- R. Carr. (km/l)

- R. Comb. (km/l)
- R. Ajust. (km/l)
- Nox (g/1000km)
- Calificación Gas Ef. Inv.
- Calificación Contam. Aire
- Tamaño (L)
- Potencia (HP)
- Híbrido

2.1. Selección de variables

Las siguientes variables fueron descartadas:

- R. Comb. (km/l)
- R. Ajust. (km/l)
- Nox (g/1000km)
- Calificación Gas Ef. Inv.
- Calificación Contam. Aire
- Versión
- Comb.

Esto, debido a que estas variables se derivan o se calculan en base a otras que ya estamos considerando, tales como R. Ciudad (km/l) y R. Carr. (km/l), con lo que si las incluimos tendríamos un problema de colinealidad. En el caso de Nox (g/1000km) y Comb. se excluyen por tener un bajo estadístico F en relación al CO₂ (g/km). La variable Versión también debe ser excluida debido a que hay muchas categorías de Versión (3,118 etiquetas de 4,601 registros), esta variable no permite un análisis al casi tener cada vehículo su propia Versión.

Con esto se corre el riesgo de tener overfitting y por lo tanto la sugerencia es remover este campo.

2.2. Estadística descriptiva básica

A continuación se presenta la matriz de correlaciones entre las variables.

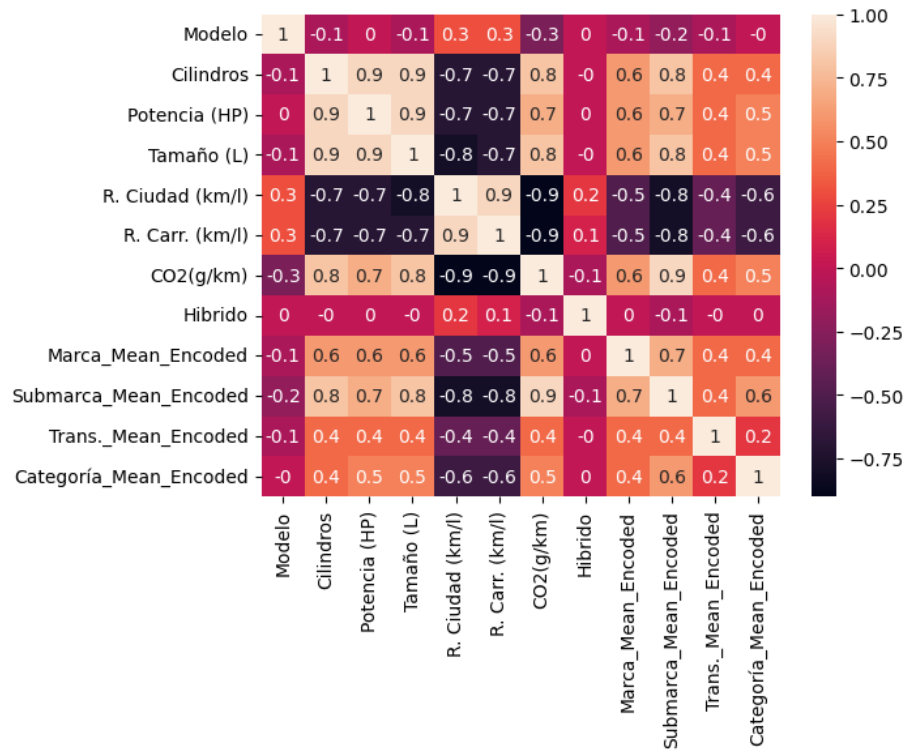


Figura 1: Matriz de correlaciones

Como se puede ver en la figura 1, las variables de Cilindros, Potencia y Tamaño son las que se encuentran más correlacionadas positivamente entre ellas. De igual forma, la variable Submarca tiene una correlación positiva alta con la variable respuesta CO_2 . Las variables de Rendimiento en Ciudad y Rendimiento en Carretera son las que presentan mayor correlación negativa con la variable respuesta CO_2 .

Abajo se muestran las principales estadísticas descriptivas de cada variable.

	Modelo	Cilindros	Potencia (HP)	Tamaño (L)
Conteo	4601	4601	4601	4601
Media	2014.18	5.33	255.29	2.87
Desviación	2.16	1.8	132.920000	1.350000
Min	2011	3	60	0.9
25 %	2012	4	150	1.8
50 %	2014	4	220	2.5
75 %	2016	6	330	3.6
Max	2018	12	888	8.4

Cuadro 1: Estadística descriptiva 1

	R. Ciudad (km/l)	R. Carr. (km/l)	CO2(g/km)	Hibrido
Conteo	4601	4601	4601	4601
Media	10.6	16.6	256.73	0.01
Desviación	3.29	4.19	75.63	0.1
Min	3.1	6.7	107	0
25 %	8.2	13.44	200	0
50 %	10.42	16.39	244	0
75 %	12.82	19.6	299	0
Max	27.46	31.3	627	1

Cuadro 2: Estadística descriptiva 2

3. Preprocesamiento

Se generó el campo Hibrido con un 1 si el vehículo es híbrido y 0 si no lo es, en base a la descripción del vehículo que se podía extraer de los campos Versión y Submarca. Se eliminaron los registros con valores nulos y se redefinieron las variables categóricas usando el método de Mean Encoding.

4. Agrupamiento

Se realizó un agrupamiento para la variable Submarca con CO_2 por el método de K-Medias.

Primero se obtuvo que la cantidad de grupos adecuada era $K = 4$ de acuerdo al gráfico de codo.




Figura 2: Gráfica de codo

El resultado de emplear K-medias para agrupar las submarcas se puede apreciar en la figura 3.




Figura 3: Gráfica de codo

Referencias

Información sobre las tendencias de emisiones de CO₂ y rendimiento de combustible en Estados Unidos (en inglés): EPA. (2016). Light-Duty Automotive Technology, Carbon Dioxide Emissions, and Fuel Economy Trends: 1975 Through 2016, United States Environmental Protection Agency (EPA).

Información sobre las tendencias mundiales de emisiones de gases de efecto mundiales provenientes de vehículos de pasajeros y rendimiento de combustible (en inglés): An, F., Gordon, D., He, H., Kodjak, D., & Rutherford, D. (2007). Passenger Vehicle Greenhouse Gas and Fuel Economy Standards: A Global Update, The International Council on Clean Transportation (ICCT).

Información sobre las diferencias que existen entre el rendimiento ajustado por la EPA y el rendimiento observado consultar el documento (en inglés): Greene, D., Goeltz, R., Hopson J. (2005). Analysis of In-Use Fuel Economy Shortfall by Means of Voluntarily Reported Fuel Economy Estimates.